

11 | 怎么给字符串字段加索引？

time.geekbang.org/column/article/71492

11 | 怎么给字符串字段加索引？

林晓斌 2018-12-07



烁

00:00

1.0x *听*

讲述：林晓斌 大小：11.70M 时长：12:46

现在，几乎所有的系统都支持邮箱登录，如何在邮箱这样的字段上建立合理的索引，是我们今天要讨论的问题。

假设，你现在维护一个支持邮箱登录的系统，用户表是这么定义的：

```
mysql> create table SUser(
```

```
ID bigint unsigned primary key,
```

```
email varchar(64),
```

```
...
```

```
)engine=innodb;
```

由于要使用邮箱登录，所以业务代码中一定会出现类似于这样的语句：

```
mysql> select f1, f2 from SUser where email='xxx';
```

从第 4 和第 5 篇讲解索引的文章中，我们可以知道，如果 email 这个字段上没有索引，那么这个语句就只能做全表扫描。

同时，MySQL 是支持前缀索引的，也就是说，你可以定义字符串的一部分作为索引。默认地，如果你创建索引的语句不指定前缀长度，那么索引就会包含整个字符串。

比如，这两个在 email 字段上创建索引的语句：

```
mysql> alter table SUser add index index1(email);
```

或

```
mysql> alter table SUser add index index2(email(6));
```

第一个语句创建的 index1 索引里面，包含了每个记录的整个字符串；而第二个语句创建的 index2 索引里面，对于每个记录都是只取前 6 个字节。

那么，这两种不同的定义在数据结构和存储上有什么区别呢？如图 2 和 3 所示，就是这两个索引的示意图。

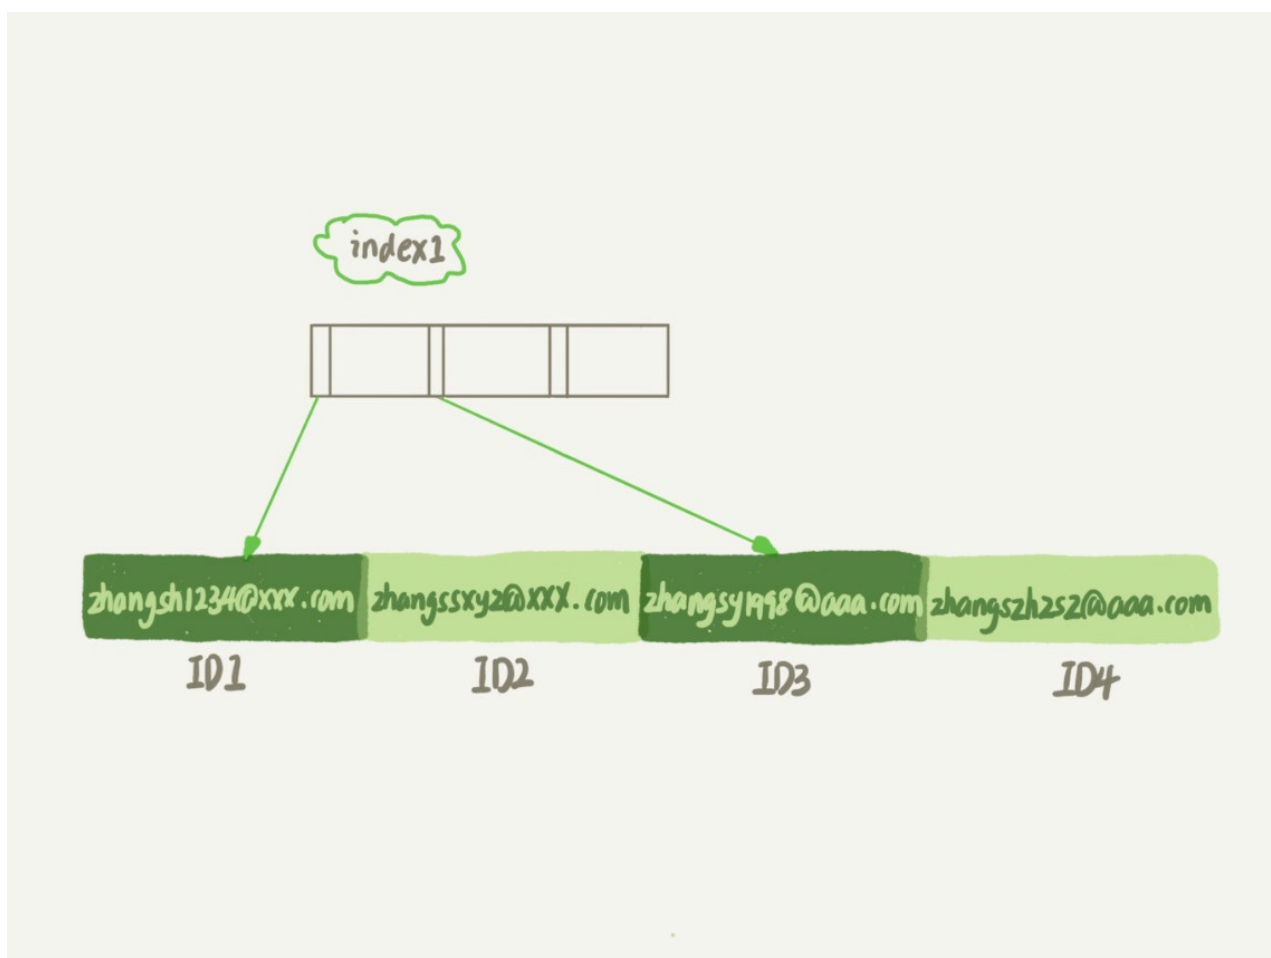


图 1 email 索引结构




图 2 email(6) 索引结构

从图中你可以看到，由于 email(6) 这个索引结构中每个邮箱字段都只取前 6 个字节（即：zhangs），所以占用的空间会更小，这就是使用前缀索引的优势。

但，这同时带来的损失是，可能会增加额外的记录扫描次数。

接下来，我们再看看下面这个语句，在这两个索引定义下分别是怎么执行的。

```
select id,name,email from SUser where email='zhangssxyz@xxx.com';
```

如果使用的是 index1（即 email 整个字符串的索引结构），执行顺序是这样的：

从 index1 索引树找到满足索引值是 'zhangssxyz@xxx.com' 的这条记录，取得 ID2 的值；

到主键上查到主键值是 ID2 的行，判断 email 的值是正确的，将这行记录加入结果集；

取 index1 索引树上刚刚查到的位置的下一条记录，发现已经不满足 email='zhangssxyz@xxx.com' 的条件了，循环结束。

这个过程中，只需要回主键索引取一次数据，所以系统认为只扫描了一行。

如果使用的是 index2（即 email(6) 索引结构），执行顺序是这样的：

从 index2 索引树找到满足索引值是 'zhangs' 的记录，找到的第一个是 ID1；

到主键上查到主键值是 ID1 的行，判断出 email 的值不是'zhangssxyz@xxx.com'，这行记录丢弃；

取 index2 上刚刚查到的位置的下一条记录，发现仍然是'zhangs'，取出 ID2，再到 ID 索引上取整行然后判断，这次值对了，将这行记录加入结果集；

重复上一步，直到在 idxe2 上取到的值不是'zhangs'时，循环结束。

在这个过程中，要回主键索引取 4 次数据，也就是扫描了 4 行。

通过这个对比，你很容易就可以发现，使用前缀索引后，可能会导致查询语句读数据的次数变多。

但是，对于这个查询语句来说，如果你定义的 index2 不是 email(6) 而是 email(7)，也就是说取 email 字段的前 7 个字节来构建索引的话，即满足前缀'zhangss'的记录只有一个，也能够直接查到 ID2，只扫描一行就结束了。

也就是说使用前缀索引，定义好长度，就可以做到既节省空间，又不用额外增加太多的查询成本。

于是，你就有个问题：当要给字符串创建前缀索引时，有什么方法能够确定我应该使用多长的前缀呢？

实际上，我们在建立索引时关注的是区分度，区分度越高越好。因为区分度越高，意味着重复的键值越少。因此，我们可以通过统计索引上有多少个不同的值来判断要使用多长的前缀。

首先，你可以使用下面这个语句，算出这个列上有多少个不同的值：

```
mysql> select count(distinct email) as L from SUser;
```

然后，依次选取不同长度的前缀来看这个值，比如我们要看一下 4~7 个字节的前缀索引，可以用这个语句：

```
mysql> select  
count(distinct left(email,4)) as L4,  
count(distinct left(email,5)) as L5,  
count(distinct left(email,6)) as L6,  
count(distinct left(email,7)) as L7,  
from SUser;
```

当然，使用前缀索引很可能会损失区分度，所以你需要预先设定一个可以接受的损失比例，比如 5%。然后，在返回的 L4~L7 中，找出不小于 $L * 95\%$ 的值，假设这里 L6、L7 都满足，你就可以选择前缀长度为 6。

前缀索引对覆盖索引的影响

前面我们说了使用前缀索引可能会增加扫描行数，这会影响到性能。其实，前缀索引的影响不止如此，我们再看一下另外一个场景。

你先来看看这个 SQL 语句：

```
select id,email from SUser where email='zhangssxyz@xxx.com';
```

与前面例子中的 SQL 语句

```
select id,name,email from SUser where email='zhangssxyz@xxx.com';
```

相比，这个语句只要求返回 id 和 email 字段。

所以，如果使用 index1（即 email 整个字符串的索引结构）的话，可以利用覆盖索引，从 index1 查到结果后直接就返回了，不需要回到 ID 索引再去查一次。而如果使用 index2（即 email(6) 索引结构）的话，就不得不回到 ID 索引再去判断 email 字段的值。

即使你将 index2 的定义修改为 email(18) 的前缀索引，这时候虽然 index2 已经包含了所有的信息，但 InnoDB 还是要回到 id 索引再查一下，因为系统并不确定前缀索引的定义是否截断了完整信息。

也就是说，使用前缀索引就用不上覆盖索引对查询性能的优化了，这也是你在选择是否使用前缀索引时需要考虑的一个因素。

其他方式

对于类似于邮箱这样的字段来说，使用前缀索引的效果可能还不错。但是，遇到前缀的区分度不够好的情况时，我们要怎么办呢？

比如，我们国家的身份证号，一共 18 位，其中前 6 位是地址码，所以同一个县的人的身份证号前 6 位一般会是相同的。

假设你维护的数据库是一个市的公民信息系统，这时候如果对身份证号做长度为 6 的前缀索引的话，这个索引的区分度就非常低了。

按照我们前面说的方法，可能你需要创建长度为 12 以上的前缀索引，才能够满足区分度要求。

但是，索引选取的越长，占用的磁盘空间就越大，相同的数据页能放下的索引值就越少，搜索的效率也就会越低。

那么，如果我们能够确定业务需求里面只有按照身份证进行等值查询的需求，还有没有别的方法呢？这种方法，既可以占用更小的空间，也能达到相同的查询效率。

答案是，有的。

第一种方式是使用倒序存储。如果你存储身份证号的时候把它倒过来存，每次查询的时候，你可以这么写：

```
mysql> select field_list from t where id_card = reverse('input_id_card_string');
```

由于身份证号的最后 6 位没有地址码这样的重复逻辑，所以最后这 6 位很可能就提供了足够的区分度。当然了，实践中你不要忘记使用 `count(distinct)` 方法去做个验证。

第二种方式是使用 hash 字段。你可以在表上再创建一个整数字段，来保存身份证的校验码，同时在这个字段上创建索引。

```
mysql> alter table t add id_card_crc int unsigned, add index(id_card_crc);
```

然后每次插入新记录的时候，都同时用 `crc32()` 这个函数得到校验码填到这个新字段。由于校验码可能存在冲突，也就是说两个不同的身份证号通过 `crc32()` 函数得到的结果可能是相同的，所以你的查询语句 `where` 部分要判断 `id_card` 的值是否精确相同。

```
mysql> select field_list from t where id_card_crc=crc32('input_id_card_string') and  
id_card='input_id_card_string'
```

这样，索引的长度变成了 4 个字节，比原来小了很多。

接下来，我们再一起看看使用倒序存储和使用 hash 字段这两种方法的异同点。

首先，它们的相同点是，都不支持范围查询。倒序存储的字段上创建的索引是按照倒序字符串的方式排序的，已经没有办法利用索引方式查出身份证号码在 `[ID_X, ID_Y]` 的所有市民了。同样地，hash 字段的方式也只能支持等值查询。

它们的区别，主要体现在以下三个方面：

从占用的额外空间来看，倒序存储方式在主键索引上，不会消耗额外的存储空间，而 hash 字段方法需要增加一个字段。当然，倒序存储方式使用 4 个字节的前缀长度应该是不够的，如果再长一点，这个消耗跟额外这个 hash 字段也差不多抵消了。

在 CPU 消耗方面，倒序方式每次写和读的时候，都需要额外调用一次 `reverse` 函数，而 hash 字段的方式需要额外调用一次 `crc32()` 函数。如果只从这两个函数的计算复杂度来看的话，`reverse` 函数额外消耗的 CPU 资源会更小些。

从查询效率上看，使用 hash 字段方式的查询性能相对更稳定一些。因为 `crc32` 算出来的值虽然有冲突的概率，但是概率非常小，可以认为每次查询的平均扫描行数接近 1。而倒序存储方式毕竟还是用的前缀索引的方式，也就是说还是会增加扫描行数。

小结

在今天这篇文章中，我跟你聊了聊字符串字段创建索引的场景。我们来回顾一下，你可以使用的方式有：

直接创建完整索引，这样可能比较占用空间；

创建前缀索引，节省空间，但会增加查询扫描次数，并且不能使用覆盖索引；

倒序存储，再创建前缀索引，用于绕过字符串本身前缀的区分度不够的问题；

创建 hash 字段索引，查询性能稳定，有额外的存储和计算消耗，跟第三种方式一样，都不支持范围扫描。

在实际应用中，你要根据业务字段的特点选择使用哪种方式。

好了，又到了最后的问题时间。

如果你在维护一个学校的学生信息数据库，学生登录名的统一格式是“学号 @gmail.com”，而学号的规则是：十五位的数字，其中前三位是所在城市编号、第四到第六位是学校编号、第七位到第十位是入学年份、最后五位是顺序编号。

系统登录的时候都需要学生输入登录名和密码，验证正确后才能继续使用系统。就只考虑登录验证这个行为的话，你会怎么设计这个登录名的索引呢？

你可以把你的分析思路和设计结果写在留言区里，我会在下一篇文章的末尾和你讨论这个问题。感谢你的收听，也欢迎你把这篇文章分享给更多的朋友一起阅读。

上期问题时间

上篇文章中的第一个例子，评论区有几位同学说没有复现，大家要检查一下隔离级别是不是 RR（Repeatable Read，可重复读），创建的表 t 是不是 InnoDB 引擎。我把复现过程做成了一个视频，供你参考。

Sorry, your browser doesn't support embedded videos.

曦

在上一篇文章最后，我给你留的问题是，为什么经过这个操作序列，explain 的结果就不对了？这里，我来为你分析一下原因。

delete 语句删掉了所有的数据，然后再通过 call idata() 插入了 10 万行数据，看上去是覆盖了原来的 10 万行。

但是，session A 开启了事务并没有提交，所以之前插入的 10 万行数据是不能删除的。这样，之前的数据每一行数据都有两个版本，旧版本是 delete 之前的数据，新版本是标记为 deleted 的数据。

这样，索引 a 上的数据其实就有两份。

然后你会说，不对啊，主键上的数据也不能删，那没有使用 force index 的语句，使用 explain 命令看到的扫描行数为什么还是 100000 左右？（潜台词，如果这个也翻倍，也许优化器还会认为选字段 a 作为索引更合适）

是的，不过这个是主键，主键是直接按照表的行数来估计的。而表的行数，优化器直接用的是 show table status 的值。

这个值的计算方法，我会在后面有文章为你详细讲解。

```
mysql> explain select * from t where a between 10000 and 20000;
+----+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+
| id | select_type | table | partitions | type | possible_keys | key | key_len | ref | rows | filtered | Extra |
+----+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+
| 1 | SIMPLE | t | NULL | ALL | a | NULL | NULL | NULL | 104128 | 50.00 | Using where |
+----+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+
1 row in set, 1 warning (0.01 sec)
```

```
mysql> show table status like 't'\G
***** 1. row *****
      Name: t
      Engine: InnoDB
      Version: 10
      Row_format: Dynamic
      Rows: 104128
      Avg_row_length: 85
      Data_length: 8929280
      Max_data_length: 0
      Index_length: 13664256
      Data_free: 4194304
      Auto_increment: 300001
      Create_time: 2018-12-06 17:45:49
      Update_time: 2018-12-06 17:48:55
      Check_time: NULL
      Collation: latin1_swedish_ci
      Checksum: NULL
      Create_options:
      Comment:
1 row in set (0.00 sec)
```

评论区留言点赞板：

@斜面镜子 Bill 的评论最接近答案；

@某、人 做了两个很不错的对照试验；

@ye7zi 等几位同学很认真的验证，赞态度。大家的机器如果 IO 能力比较差的话，做这个验证的时候，可以把 innodb_flush_log_at_trx_commit 和 sync_binlog 都设置成 0。

优惠充值推荐

极客时间充值卡

— 充值享优惠，学习更高效 —



© 版权归极客邦科技所有，未经许可不得传播售卖。页面已增加防盗追踪，如有侵权极客邦将依法追究其法律责任。



wallace

Command + Enter 发表

0/2000字

提交留言

精选留言(143)



封建的风


原谅我偷懒的想法，一个学校每年预估2万新生，50年才100万记录，能节省多少空间，直接全字段索引。省去了开发转换及局限性风险，碰到超大量迫不得已再用后两种办法

作者回复：从业务量预估优化和收益，这个意识很好呢 🍵 🍵

2018-12-08

猫 10

娘 228



小文

首先排除全部索引，占空间，其次排除前缀索引，区分度不高，再排除倒序索引，区分度还没前缀索引高。

最后hash索引适合，而且只是登录检验，不需要范围查询。

2018-12-07

猫 2

娘 49



老杨同志

老师整篇都讲的是字符串索引，但是思考题的学号比较特殊，15位数字+固定后缀"@gmail.com"

这种特殊的情况，可以把学号使用bigint存储,占4个字节，比前缀索引空间占用要小。跟hash索引比，也有区间查询的优势

作者回复: Bigint 8 个字节哦，赞思路。

嗯问题不是唯一答案，大家集思广益哈

2018-12-07

瑞 1

娟 43



某、人

老师针对上一期的答案有两个问题:

1.为什么事务A未提交,之前插入的10W数据不能删除啊?不是应该都进undo和change buffer了嘛,

根据mvcc查之前的版本就可以了啊。

2.不明白为什么第二次调用插入的存储过程,id就变为100000-200000,id是固定插入的,又不是自增的

作者回复: 1. 这里说的“不能删”，其实就是说的，undo log不能删，逻辑上还在

2. 你说的对... 😊我最开始的例子是用自增主键，改完自己晕了，堪误了哈

2018-12-07

瑞 4

娟 27



进阶的码农

老师按照你视频里的例子又做了一下还是不行

mysql版本8.0.12

```
+-----+
| version() |
+-----+
| 8.0.12 |
+-----+
```

是innodb 隔离级别是RR

1.先打开一个客户端A 执行start transaction with consistent snapshot;没有commit

2.然后在重新打开一个mysql客户端B 执行

delete from t;call idata(); explain select * from t between 10000 and 20000;

```
+---+-----+-----+-----+-----+-----+-----+-----+-----+-----+
-----+
| id | select_type | table | partitions | type | possible_keys | key | key_len | ref |
rows | filtered | Extra |
+---+-----+-----+-----+-----+-----+-----+-----+-----+-----+
```

```

-----+
| 1 | SIMPLE | t | NULL | range | a | a | 5 | NULL | 10001 | 100.00 | Using index
condition |
+---+-----+-----+-----+-----+-----+-----+-----+-----+---
-----+

```

2018-12-07

满 1

娟 26



小潘

可以考虑根据字符串字段业务特性做进制压缩，业务上一般会限制每个字符的范围(如字母数字下划线)。

从信息论的角度看，每个字节并没有存8 bit的信息量。如果单个字符的取值只有n种可能性(把字符转成0到n-1的数字)，可以考虑把n进制转为为更高进制存储(ascii可看做是128进制)。

这样既可以减少索引长度，又可以很大程度上兼顾前缀匹配。

作者回复: 这个有点高端了☺

2018-12-07

满

娟 19




lttzzlll

只取 四位年份+五位编号 并转化为int类型作为唯一主键

2018-12-07

猫 1

娵 14



不似旧日

因为mail的格式是学号@gmail.com ,所以@gmail.com可以不存储,使用倒叙前缀索引即可

2019-03-27

猫

娘 11



某、人

回答下今天老师的问题:

1.在user建立索引,由于学号的最后7位才能确定到某个学生.不满足最左前缀,那么select from where '%1234567%'无法使用索引,是全表扫描。但是这种情况也有优化的办法,如果该表上的字段比较多,可以这样改写select password from t join (select id from where user like '%1234567%') as a on a.id=t.id

通过全扫描二级索引得到唯一id值.再用id值与t表关联的时候,就能迅速的定位到某一行,避免全表扫描

不过在本次问题里,这种方式效果不好

2.hash索引,建立(hashuser,user,password)索引,不用回表,覆盖索引,但是索引占用长度长。

或者建立(hashuser)索引,因为hashuser基本上能确定到唯一值,虽然回表但是扫描的行数也就两行,效率也挺高。但是hash索引对于insert和update操作要多做一些额外的操作。要嘛通过程序计算出hash值,插入表里,要嘛就通过触发器来做。


3.建立前缀索引,由于后面是固定email,可以考虑只存学号.由于学号后面7位就能确定到某一个学生,可以用倒序存储+前缀索引。不过由于前缀索引不能在int类型上建立,只能用varchar类型。虽然前缀索引无法用到覆盖索引,不过回表扫描的行数也就一行,效率也挺高。这种方式来说,对insert和update相对还好。还有前缀索引还有个影响是不能用于排序。

2018-12-08

瑞

娟 11

•



这就是当下的教育体系

每个人都是天才。但是如果你以爬树的本领来判断一条鱼的能力，那它终其一生都会以为自己是个笨蛋。

—— 爱因斯坦

WL

把该讲内容总结为几个问题, 大家复习的时候可以先尝试回答这些问题检查自己的掌握程度:

1.
采用整个字符串作为索引. 在查询操作时, 执行顺序是怎样的?
2.
采用部分字段做索引, 在查询操作时, 执行顺序是怎样的?
3.
使用什么语句可以分析不同长度前缀的索引区分度是多少?
4.
前缀索引相比较整个字段做索引有什么优势和劣势?
5.
采用反序存储和hash字段作为索引有什么异同点?

2018-12-09

瑞

娘 9



Tony Du

对于上一期的问题的回答，“索引 a 上的数据其实就有两份”，是不是这样理解，其中一份是已经被标记为deleted的数据，另一份是新插入的数据，对索引数据的预估把已经被标记为deleted的数据也算上去了？MySQL对索引数据的预估为什么不去check 被标记为deleted的数据？

这种场景一旦发生，就会导致预估索引数据不准确，有什么好的方法去避免和解决？

作者回复：理解对的，

方法就是避免长事务（session A 就是模拟一个长事务）

2018-12-07

瑞

娟 9



CCCCC

实际操作上直接全字段索引就行了，一个学校数据库的数据量和查询压力都不会大到哪儿去。

如果单从优化数据表的角度：

1. 后缀@gmail可以单独一个字段来存，或者用业务代码来保证，
2. 城市编号和学校编号估计也不会变，也可以用业务代码来配置
3. 然后直接存年份和顺序编号就行了，这个字段可以全字段索引

2019-03-23

满

嫵 8



Hunter

是不是还是之前的思路，把邮件的地址里面@的前一段做倒排存储，然后就可以使用前缀索引了。

或者也可以用年份和顺序号单独存一列，这样就有点类似哈希了，优点是还可以支持范围查询。

2018-12-07

满

嫵 8



Livis

课后题思考：可以使用学号拼接密码构建一个hash值，每次登录校验时重新计算hash值匹配；

2018-12-07

瑞

姐 5



叶剑峰

我觉得建立索引和插入数据在实际生产过程中可能是相互迭代的。先建立索引--后插入数据--再优化索引，再插入数据，所以文中说的几种方法都要知道下，具体不同情况不同看。像人员表邮箱这个字段，会先建立全字符串索引，要是业务发展到人员表暴增，导致磁盘比较多，才会想到优化某种长度的字符串索引

作者回复: 差不多是这样的

一般在你说的这个迭代之前，会再多一个“业务量预估”☺

2019-01-16

瑞

姐 4



一撮韶光

删的时候，由于有未提交事务开启的一致性视图read-view，所以导致了存在两个数据版本的数据，貌似优化器在"看"二级索引的时候，"看到"了多个历史版本的数据，错误以为有很多数据

而主键索引数量由于确认机制不同，数量没有变，综合考虑，优化器选择了主键索引
作者回复:

2018-12-09

满

娘 4



alioo

去掉@gmail.com后倒序存储，取7位创建前缀索引

2019-08-26

满

娘 3



马若飞

通常我们都是创建表的时候根据业务创建索引，这时候分析前缀没意义，因为没数。等表大了上千万行后再执行前缀分析也不合适啊。

另外，不是不推荐在where中使用函数吗？使用reverse不影响性能？

2018-12-12

满3

娟3



一步

前缀索引和整个字段的索引在索引树上是没有区分的吗？能不能通过某个属性判断一个索引是不是前缀索引？

还有个问题，就是文中使用整个字段的索引的时候，取出邮箱的值后还要回表判断一下邮箱是否正确，但是下面讲解覆盖索引的时候又不需要回表判断邮箱的值是否正确，这个如果是整个字段的索引就不需要回表判断是否正确了吧

下面是文中的内容

如果使用的是 index1（即 email 整个字符串的索引结构），执行顺序是这样的：从 index1 索引树找到满足索引值是 'zhangssxyz@xxx.com' 的这条记录，取得 ID2 的值；到主键上查到主键值是 ID2 的行，判断 email 的值是正确的，将这行记录加入结果集；取 index1 索引树上刚刚查到的位置的下一条记录，发现已经不满足 email='zhangssxyz@xxx.com' 的条件了，循环结束。

2019-11-13

满2

娘 2

•



菜鸟

老师，请教您一个问题，上一章的问题，由于session A 的一致性非锁定读，session B delete之后，undo log肯定不能purge。那么在insert之前，物理磁盘上的 数据页 和 索引页 是真正的删除，还是打个已delete的标记呢，还是什么也不做？如果是打个delete标记，那么下一步如果进行rollback, 是把delete标记去掉吗？

2019-08-05

猫

娘 1

收起评论祇